2024 Summary

这学期，我主要了解了，大小模型协同，无人机视觉语言导航，生成式交互环境，持续学习，端到端自动驾驶，和视频个体计数等六个问题，下面我简单汇报一下。

大小模型协同

第一个问题是大小模型协同， 先认识一下，什么是大模型，Foundation model 是指拥有大量参数，通过预训练，拥有泛化能力的模型，大致可分为大语言模型和多模态大模型， （学习一下 CLIP、VAE、）

大小模型端云协同进化技术进展

了解了大模型小型化，和大小模型协同的知识，其中，大模型小型化，主要有三种方法，模型剪枝，模型量化，和知识蒸馏，模型剪枝指的是去除大模型中冗余的参数，模型量化指的是将模型参数范围降低，将浮点型模型转化为定点型模型，知识蒸馏是指，让小模型模仿大模型的行为，然后将大模型的知识迁移到小模型中。

大小模型协同也分为三个部分，协同训练是指大小模型通过特征传递等方法同时训练，协同推理是指将任务划分为不同的模块，然后分配给不同大小的模型进行推理，然后合并推理的结果，协同规划文中说的比较笼统，就是单一模型难以完成任务规划，需要多模型协同规划。

UAVs

模型: LSTM, ResNet, recurrent network, attention mechanism, GRU,

方法的话，文中提出了一个 baseline model ，就是将深度图、 RGB 图像、上一次隐藏表示和上一次动作输入到 GRU 中，获得这一次的隐藏表示，指令使用 LSTM 处理，

还有一种 seq2seq 的方法，除去这里面的 attention 方法，大致差不多，不过没有直接输出 action ，而是通过隐藏表示输出一个机率分布，然后选择最大概率的 action 输出。

学到了，了解如何处理语言和图像多模态融合的方法。

Generative Interactive Environments

本文作者试图完成，在生成模型基础上，增加交互体验。

本文中方法的关键是 ST-transformer,

Genie 方法通过分析（超过 200,000 小时）没有动作或文本的标注的公开网络游戏视频大数据集进行训练，可以实现对每一帧的精确控制，这是通过学习到的潜在动作空间 (latent action space) 实现的。

Genie 基于最先进视频生成模型的理念，其核心设计是采用时空 (spatiotemporal, ST) transformers ，这一技术被应用于所有模型组件。 Genie 引入了一种新颖的视频 token 化技术，并通过因果动作模型提取潜在动作。这些视频 token 和潜在动作被送入一个动态模型中，该模型使用 MaskGIT 技术自回归地预测下一帧。

与传统需要直接从环境获取动作数据的模型学习不同，团队探索了一种新路径：仅利用视频数据，以无监督的方式学习构建世界模型。

重要的是，该模型是在没有动作或者文本标注的网络游戏视频大数据集中进行训练的，那么，它能否是新的一种训练世界模型或者基石模型的方法，需要之后的实验来验证。

持续学习

持续学习，是指像人类一样具有持续不断的学习能力，根据历史任务中学到的经验和知识来帮助学习不断出现的新任务，并且这些经验和知识是持续积累的，不会因为新的任务而忘记旧的知识。

持续学习的最主要问题是，灾难性遗忘，就是说当模型学会了一个新的任务导致旧任务的知识适应能力大幅度下降。

另外，持续学习主要期望的能力：学习可塑性（通过历史任务的经验和知识辅助新任务的学习）和记忆稳定性（在学习新任务的同时不忘记旧的经验和知识）。

（就结果来说，持续学习应对新旧任务都可以有很强的泛化能力。）

文中将代表性的方法分成 5 个种类，分别是基于正则化方法，基于重现方法，基于优化方法，基于表示方法，和基于架构方法，

基于正则化，是显式增加正则化术语，来平衡老和新的任务，重现方法是指，近似和恢复老数据分布的方法，优化方法是，显式设计和操作优化程序，基于表示是创造和利用表示的优势，基于架构是构架任务指定参数。

端到端自动驾驶

传统的自动驾驶方法通过将感知、决策、控制等模块分开设计，使得每个模块独立优化。然而，这种方法在复杂环境中面临诸多局限，模块间目标不一致和误差传播问题突出。因此，端到端方法应运而生，它通过将整个系统作为一个统一的可微分模型，允许直接从传感器数据到控制指令的端到端学习。

端到端系统的优势在于通过一个整体框架优化各模块之间的协同作用，同时通过数据驱动方法持续提升系统的自适应能力和性能。

端到端自动驾驶方法主要分为模仿学习和强化学习两种。

视频个体计数

在视频群众计数（Video Crowd Counting , VCC）的基础上提出。 VCC 是指计数视频中每一帧的人数，而视频个体计数（Video Individual Counting , VIC）是指在给定的视频中，计数个体的总数，要求每个个体只计数一次。

目前的方法主要有三种：

DRNet

作者提出在 VCC 基础上，提出精确计算视频中每个人独一无二的计数任务。

关键是将特征匹配看成任务分配问题，然后使用匈牙利算法或者其他算法求解，

CGNet

作者提出弱监督任务，旨在降低使用独一无二标签的昂贵消耗，

关键是使用群匹配策略，然后使用匈牙利算法进行分配，同时为了解决退出又重新进入的人群，提出了 TTL 这个参数用于计时相同的人。

相邻帧图像的表示被分成四个群组， X 是。。。 Locator 预测行人的坐标， Encoder 生成每个人的表示， MCP 预测流入的人数，并且更新在内存中的模板。 弱监督表示学习，是训练 编码器，使匹配的群组更接近，不匹配的群组更远，使用一个 GML 损失来训练。

PDTR

动机：减少对密度图和描述符正确性的依赖，以及减少一些额外的预处理操作。

作者提出使用 transformer 来获取相邻帧中的相似和差异信息，为了解决匹配算法预处理和对密度图依赖的影响。

关键是，用 transformer 来获取相邻帧中的相似和差异信息，然后对相邻两帧的相似特征进行提取，然后根据输入特征和相似特征，预测出每帧的私有特征，然后根据特征回归到图像的坐标中。

因为只是考虑相邻两帧图像的差异，所以没有考虑退出又重新进入的人群。